

ADAM2_database_57385.xlsx 資料品質審核報告

國立臺灣海洋大學 · 2026 年 10 月 6 日

本報告檢查 ADAM2_database_57385.xlsx (共 57,385 筆資料) 的三個問題：胜肽名稱為何缺漏、現有文獻是否正確，以及從來源資料庫取得的文獻資訊是否正確。審核過程僅讀取資料，未修改檔案內容。文獻部分以隨機抽樣方式，直接與 PubMed 資料庫比對驗證。

重點摘要

- **胜肽名稱缺漏**：共 3,953 筆 (6.9%)，其中 84% 來自 dbAMP3。極可能是來源資料庫原本就沒有名稱。
- **現有文獻**：大致正確。抽樣比對 PubMed，真正錯誤的比例約 1%。
- **從來源資料庫取得的文獻**：有一個重大問題——12,757 筆專利來源的資料，在「PubMed ID」欄位中放的其實是**專利號碼**，而非 PubMed ID。

問題一：為什麼有些胜肽名稱缺漏？

共有 3,953 筆資料 (6.9%) 沒有胜肽名稱。缺漏幾乎集中在單一來源資料庫：

來源資料庫	資料筆數	缺少名稱	缺漏比例
dbAMP3	7,142	3,303	46%
DBAASP	1,307	136	10%
DRAMP	32,781	394	1.2%
CAMP	16,155	120	0.7%

結論：極可能是來源資料庫原本就缺少名稱。這些資料大多除了序列之外什麼都沒有——沒有文獻、沒有 UniProt 連結，通常也沒有活性資訊。這符合「來源資料庫從未為其命名」的情況，而不像是在合併資料時遺失了名稱。

但有兩點需要注意：

- 有 **183** 筆可以補回名稱。同一條序列在本檔案的其他資料列中有名稱（大多數為 dbAMP3）。
- **無法百分之百證實**。本檔案沒有保留原始資料庫的編號（例如 DRAMP、CAMP 或 dbAMP 的 ID），因此無法將任何一筆資料追溯回其來源紀錄。這一點本身就值得改善。

問題二：現有的文獻來源是否正確？

大致正確。我們隨機抽樣，直接與 PubMed 比對：

來源資料庫	抽樣檢查內容	結果
DRAMP	150 筆：文獻標題是否與 PubMed 一致	146 筆完全一致；真正指向錯誤文獻的僅 1 筆（約 1%）
CAMP	150 筆：PubMed ID 是否存在、主題是否相符	150 筆全部存在，且均為抗菌肽相關主題

DRAMP 不一致的 4 筆中，有 2 筆是標題在特殊字元處被截斷，例如「The CD8」原應為「The CD8+ ...」。全檔約有數十筆標題有類似的截斷情形，另有 2 筆標題含亂碼字元。作者欄位沒有發現亂碼。

另外，CAMP 的資料只有 PubMed ID，沒有文獻標題和作者。

問題三：從資料庫取得的文獻來源是否正確？

有一大類資料不正確。共有 **12,757** 筆資料（幾乎全部是 DRAMP 中的專利序列），其

「PubMed ID」欄位中放的是被截短的專利號碼，而不是 PubMed ID。例如：

名稱：Sequence 261 from Patent US 20120052048

PubMed ID 欄位：0052048（即專利號碼的最後 7 位數）

其中 7,525 筆的號碼被截成最後 7 位數。若把這些號碼當成 PubMed ID 去查詢，會連到完全不相關的 1970 年代論文，例如〈阿肯色州血液酒精檢測計畫〉。

項目	筆數
有填寫「PubMed ID」的資料	42,587
其中實際上是專利號碼	12,757 (30%)
真正有文獻來源的資料	29,830

也就是說，看起來有文獻的資料中，有 30% 其實沒有文獻。此外，dbAMP3 和 DBAASP 的資料完全沒有任何文獻資訊。

僅憑這個檔案，無法判斷專利號碼是 DRAMP 原始匯出時就已存在，還是在合併資料時才產生的。需要比對 DRAMP 的原始下載資料才能確認。

建議

- **修正專利資料：**將 12,757 筆專利號碼從「PubMed ID」欄位移到獨立的「專利號碼」欄位，避免網站顯示錯誤的 PubMed 連結。
- **補回名稱：**利用相同序列，補上 183 筆可回復的胜肽名稱。
- **保留來源編號：**在資料中加入原始資料庫的 ID，讓每筆資料都能追溯回來源。
- **與原始資料比對：**下載 DRAMP 原始資料，確認專利號碼問題是在哪個階段產生的。

備註：目前 ADAM 網站仍使用舊版資料檔 (ADAMV2(2).xlsx) 顯示資料，因此上述問題尚未影響線上網站。若改用此新檔案，專利資料將會顯示錯誤的 PubMed 連結，建議先修正後再切換。